

学校代码： 10347
分 类 号： TP39

密 级： _____

湖州师范学院
硕 士 学 位 论 文
(专业学位)



基于计算机视觉的鱼类活跃度分类模型研究
Research on Fish Activity Classification Model Based on
Computer Vision

作 者 姓 名：	童欣
学 号：	2021388314
所 在 学 院：	信息工程学院
专业学位类别：	电子信息
专业学位领域：	计算机技术
指 导 教 师：	徐立鸿、蒋林华
论文完成日期：	2024 年 5 月

摘 要

鱼类活跃度作为反映鱼群整体状态的指标，能够很好的辅助提升健康养殖技术和鱼类福利，同时提高养殖业的经济效益。在现代鱼类养殖领域，实时视频监控已成为普遍使用的辅助鱼类养殖技术。为了将计算机视觉技术能够运用到实际的鱼类养殖中去，实现鱼类福利养殖的监测，提升鱼类养殖福利和养殖经济效益。本文以大西洋鲑作为研究对象，采集工厂化循环水养殖视频，构建了一个鱼类活跃度分类数据集，建立了基于目标检测的鱼类多目标跟踪模型 YO-BYNet，鱼类活跃度分类模型 FAC-Net，以及一个鱼类福利养殖监测系统。本文的主要工作如下：

（1）采集真实鱼类养殖环境的视频，构建了鱼类活跃度分类数据集，该数据集包含三部分，分别是用于训练鱼类多目标跟踪模型 YO-BYNet 检测器的多目标检测数据集，用于训练 YO-BYNet 跟踪器的多目标跟踪数据集，用于训练鱼类活跃度分类模型 FAC-Net 的鱼类活跃度分类数据集。

（2）建立了鱼类多目标跟踪模型 YO-BYNet，用于获得活跃度特征序列，YO-BYNet 将 YOLOv8，卡尔曼滤波和 BYTE 的关联方法结合起来，并加入了 NSGA-II 遗传算法对跟踪器进行多目标优化，并使用了先进的多目标跟踪评估方法 HOTA 对提出的模型进行评估并取得了良好的效果。

（3）提出了鱼类活跃度分类模型 FAC-Net，整合了 YO-BYNet 和活跃度特征序列处理过程，并将活跃度特征序列输入到基于 Transformer 的时间序列模型 PatchTST 和分类器中，对鱼类活跃度进行二分类，取得了良好效果，并且进行鱼类活跃度分类的速度达到了 30FPS。

（4）设计并实现了一个鱼类福利养殖监测系统，能够采集鱼类养殖视频，将视频输入到鱼类活跃度分类模型 FAC-Net 中，进行鱼类活跃度的监测及异常预警，帮助养殖相关人员发现并排查鱼类的异常情况。

关键词：鱼类福利养殖；鱼类活跃度；分类模型；多目标跟踪模型；时间序列模型

Abstract

As an indicator that reflects the overall status of fish stocks, fish activity can help improve healthy breeding techniques and fish welfare, while improving the economic benefits of the breeding industry. In the field of modern fish farming, real-time video monitoring has become a commonly used auxiliary fish farming technology. In order to apply computer vision technology to actual fish farming and realize the monitoring of fish welfare farming, this thesis takes Atlantic salmon as the research object, collects factory-scale circulating aquaculture videos, and constructs a fish activity classification dataset, established a fish multi-object tracking model YO-BYNet based on target detection, a fish activity classification model FAC-Net, and a fish welfare breeding monitoring system. The main work of this thesis is as follows:

(1) Collect videos of real fish farming environments and construct a fish activity classification dataset. This dataset contains three parts, which are multi-object detection data used to train the fish multi-object tracking model YO-BYNet detector. Set, a multi-object tracking dataset used to train the YO-BYNet tracker, and a fish activity classification dataset used to train the fish activity classification model FAC-Net.

(2) A fish multi-object tracking model YO-BYNet was established to obtain activity feature sequences. YO-BYNet combines the correlation methods of YOLOv8, Kalman filtering and BYTE, and adds the NSGA-II genetic algorithm for tracking. The machine was used for multi-objective optimization, and the advanced multi-object tracking evaluation method HOTA was used to evaluate the proposed model and achieved good results.

(3) The fish activity classification model FAC-Net is proposed, which integrates YO-BYNet and the activity feature sequence processing process, and inputs the activity feature sequence into the Transformer-based time series model PatchTST and classifier to classify fish Class activity was classified into two categories, and good results were achieved, and the speed of classifying fish activity reached 30FPS.

(4) Designed and implemented a fish welfare farming monitoring system that can collect fish farming videos and input the videos into the fish activity classification model FAC-Net to monitor fish activity and provide abnormal warnings to help farming relevant personnel discovered and investigated abnormalities in fish.

Key Words: Fish welfare breeding; Fish activity; Classification model; Multi-object tracking model; Time series model

目 录

1 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状分析.....	2
1.2.1 鱼类活跃度的研究进展.....	2
1.2.2 多目标跟踪算法的研究进展.....	3
1.2.3 时间序列模型的研究进展.....	5
1.3 研究内容.....	6
1.4 组织结构.....	7
1.5 本章小结.....	8
2 数据集采集系统与数据集构建	9
2.1 数据采集基地介绍.....	9
2.2 数据采集方案设计.....	10
2.3 鱼类活跃度分类数据集构建	11
2.3.1 鱼类多目标检测数据集构建.....	12
2.3.2 鱼类多目标跟踪数据集构建.....	12
2.3.3 鱼类活跃度分类数据集构建.....	13
2.4 本章小结.....	13
3 基于目标检测的鱼类多目标跟踪模型 YO-BYNet.....	14
3.1 YO-BYNet 模型结构	14
3.1.1 YO-BYNet 检测器	14
3.1.2 YO-BYNet 跟踪器	17
3.1.3 结合 NSGA-II 遗传算法微调跟踪器.....	20
3.2 实验结果分析.....	20
3.2.1 评价指标.....	20
3.2.2 实验结果.....	21
3.2.3 对比实验.....	23
3.3 本章小结.....	24
4 鱼类活跃度分类模型 FAC-Net.....	25
4.1 FAC-Net 模型结构.....	25
4.1.1 FAC-Net 的时间序列模型.....	25
4.1.2 FAC-Net 的分类器	28
4.2 实验结果分析.....	29
4.2.1 评估指标.....	29
4.2.2 实验结果.....	29

4.3 本章小结.....	31
5 鱼类福利养殖监测系统	32
5.1 系统介绍.....	32
5.2 应用流程.....	33
5.3 系统设计与界面.....	35
5.4 本章小结.....	38
6 总结与展望.....	39
6.1 工作总结.....	39
6.2 工作展望.....	39
参考文献.....	41

1 绪论

1.1 研究背景及意义

我国水产品生产总量位居世界各国首位，出口创汇总额处于世界领先地位^[1]。如何进一步巩固和提升我国渔业经济在全球化大循环中的竞争力，实现渔业增效、渔民增收、促进渔业经济健康、快速可持续发展，关键是要大力推行水产健康养殖技术，不断提高水产品质量与安全^[2]。发展水产健康养殖，是可持续发展的迫切需要，加大科技投入，提升科技创新，增加科技应用，是水产健康养殖发展的基础。在传统经济模式之下，之所以表现为高消耗、高污染、低产出是因为科学技术水平低，没有能力更好地合理利用资源。就拿养殖管理来讲，从低密度发展到高密度养殖，管理水平跟不上，饲料利用率低、饲料系数偏高，同时导致严重的自身污染，结果就出现了这样那样的诸多问题，如养殖环境恶化、药物滥用、药物残留、食品安全问题等等^[3]。

福利养殖理念是健康养殖的核心和基础，研究养殖福利应以研究健康养殖模式为前提。福利侧重于动物自身感受、强调动物的健康生长^[4]。对水产福利养殖可以定义为：在集约化养殖模式下，为养殖动物提供一个符合其生物学习性、适于生长和极少有胁迫感的软硬件养殖环境，并保障饲料供应充足、疾病防控措施严密和控管规程精准的一种高端养殖生产模式。

对于如何实现健康养殖，福利养殖，计算机视觉技术是其中一种很好的实现方法。计算机视觉技术因为其高效、经济、非侵害、无损等特点^{[5][6]}已经被研究者在各个领域广泛运用。之后的研究重点可以在多目标的目标跟踪复杂性较强的情况下，研究鱼群整体参数，如群体活跃程度和摄食强度等参数的量化方法及其统一化^[7]。

大西洋鲑俗称三文鱼，因其丰富的营养和显著的市场价值而受到青睐，然而养殖过程中的风险同样不容忽视。鱼类活跃度是衡量鱼群整体状况的重要指标，对于提高养殖技术和确保鱼类福利至关重要。本文通过采集工厂化循环水养殖大西洋鲑的视频，建立基于计算机视觉的鱼类多目标跟踪模型 YO-BYNet(Multi-Object Tracking of Fish Based on YOLOv8 and BYTE Association Method)，建立了鱼类活跃度分类模型 FAC-Net(Fish Activity Classification Network)，实现了对鱼类活跃度的二分类。此外，本文构建了一个实时的鱼类福利养殖监测系统，该系统能够通过 FAC-Net 分析鱼类的活跃度来辅助评估其整体的鱼类健康状况，能够及时识别鱼类健康问题，有效降低死亡率，从而提升产量。该系统能确保鱼类在一个优质的福利环境中成长，从而促进其健康发展，提高鱼类品质，加速鱼类生长速度。这不仅提升了鱼类的生活质量，也为养殖业带来了更高的经济效益。

1.2 国内外研究现状分析

1.2.1 鱼类活跃度的研究进展

即便是在相同的环境条件下,不同品种的鱼也会展现出各自独特的行为模式。这使得使用传统方法来量化鱼类行为变得极具挑战性。鱼类活跃度是研究鱼类行为的一个重要指标,它能够在一定程度上反映出鱼类行为的动态变化。鱼类活跃度反映鱼群整体的情况,影响的因素非常多,例如氧气浓度、温度、摄食、水质、应激反应、时间、养殖密度。

以大西洋鲑作为研究对象,有研究者的实验表明大西洋鲑的心率和游泳活动可以作为鱼类活跃度的指标,在一定范围内心率和游泳活动与活跃度成正比关系^[8]。也有研究人员选取了不同种类鱼作为实验对象,通过摄像机记录了鱼在不同氧和氨氮浓度条件下的游泳速度和空间分布,以此来分析鱼的行为模式。研究结果显示,在水中的溶解氧刚开始降低至正常水平以下时,鱼类的活跃度会增加,并表现出逃避行为;但在严重缺氧的情况下,活跃度会减少。对于非离子氨,低浓度并不影响鱼的活跃度,但当浓度升高到一定水平时,鱼的活跃度会增加,它们在水中的垂直分布也会上升,然而一段时间后,活跃度垂直分布都会有所下降^[9]。以鳊鱼作为研究对象,鳊鱼的活跃度与化学预警信号有关联,同时这种行为也受到外部环境因素的影响^[10]。以斑马鱼作为研究对象,斑马鱼在不同浓度的 Cu^{2+} 溶液中的活跃度表现出了显著的差异,而在 Cr^{6+} 溶液中则没有观察到这种变化^[11]。还有研究者进一步表示,尽管食物的丰度似乎对鱼类的活跃度没有直接影响,但它们的活跃度与摄食和代谢过程却有着密切的联系^[12]。以黄颡鱼作为研究对象,通过计算其在一天中不同时间段内的游动和摄食的百分比,对其活跃度的差异进行了显著性分析。研究比较了黄颡鱼的游动模式和摄食习惯,并探讨了其食物偏好。结果显示,黄颡鱼主要在夜间活动和进食,其游动活跃度受到摄食行为的影响而有所下降。黄颡鱼偏好的食物包括河虾、蚯蚓和麦穗鱼等。此外,研究还发现,比目鱼和虹鳟鱼的活跃度会随着养殖密度的提高而增加,但这同时会导致摄食率和生长率的显著下降^[13]。以比目鱼和虹鳟鱼作为研究对象,发现鱼的活跃度随着养殖密度的增加而增大,而摄食率和生长率显著降低^[14]。以中华倒刺鲃幼鱼和鲤科鱼作为研究对象,分析短期捕食和饥饿胁迫对活跃度的影响,发现当鱼类受到捕食胁迫时活跃度会增大^[15]。

实现鱼类活跃度研究的具体方式有机器学习、深度学习、轨迹分析、测量统计等。有研究者以鲫鱼为研究对象,采集鲫鱼在清澈水质中的活跃度视频,通过深度学习方法对运动的鲫鱼进行目标检测,提取多条鲫鱼的运动轨迹,计算多条鲫鱼的平均游动速度,利用鱼群的平均游速分布来划分活跃度等级^[16]。也有研究采集鱼的运动视频,将视频输入到 idTracker 软件分析鱼在视频中的运动轨迹,并将轨迹进行坐标表示。通过像素与

实物计算比例尺转化像素坐标为实际坐标。计算实验鱼移动总距离和运动时平均速度等参数。还有研究者通过计算鱼游动的数量与鱼的总数量的百分比,根据百分比将鱼类活跃度进行三分类,小于 30%为鱼类活跃度低、30%~55%为鱼类活跃度中、55%以上为鱼类活跃度高。此外,研究者将连续两帧之间的图像像素差异进行对比,将各条鱼运动所引起的变化面积与相应各条鱼的原始面积相除可近似得到各条鱼的体长倍数游动距离,一段时间内多个采样间隔里各条鱼游动距离的均值可以反映鱼类的活跃度。另外有研究通过搭建了一个五层的分类神经网络对第一阶段光流法提取的帧间运动特征进行活跃度分类^[17]。也有研究提出了一种基于深度学习的视频分类模型 SE-LRCN,模型对原始的长期卷积循环网络进行改进,在卷积神经网络部分融合了 SE 模块,引入了通道注意力机制,并将原始的 LSTM 网络替换成了 GRU 网络,以提高模型处理小型数据集的能力^[18]。

现有的部分鱼类活跃度分类方法很难应用到实际的养殖环境中,例如计算鱼的平均游动速度,在鱼较多互相遮挡和不规则运动以及水质较差时是非常难检测并计算的;例如计算鱼游动的数量与鱼的总数量的百分比,很难根据百分比科学的定活跃度分类标准;例如根据面积变化进行分类,受距离和视角的影响分类偏差会较大;例如运用光流法,光流法的计算量较大计算速度较慢,难以运用到实际的养殖中进行实时监控;例如 SE-LRCN 模型是应用在水面俯视拍摄的情况,而非水下拍摄情况,需要提取的特征方式不同。因此,本文提出了 FAC-Net 鱼类活跃度分类模型,针对工厂化循环水养殖大西洋鲑的水下情况,实现鱼类活跃度二分类,并且模型速度较快能够运用到鱼类的实时监测中。

1.2.2 多目标跟踪算法的研究进展

多目标跟踪简称 MOT(Multiple Object Tracking),主要解决的问题是对视频中的多个目标进行检测并赋予 ID 进行轨迹跟踪。多目标跟踪算法通常可以分为以下几类:

(1) 基于检测的跟踪(tracking-by-detection):这类方法首先对每一帧图像进行目标检测,然后使用数据关联算法将检测到的目标与已有的轨迹进行匹配。

(2) 基于预测的跟踪(tracking-by-prediction):这类方法依赖于运动模型来预测目标在下一帧中的位置,然后使用观测数据来更新预测结果。

(3) 联合检测和跟踪(joint detection and tracking):这类方法将目标检测和跟踪作为一个联合优化问题来求解,以提高跟踪的准确性和鲁棒性。

卡尔曼滤波^[19]是应用广泛的基础跟踪算法,是一种用于动态系统状态估计的线性滤波方法。卡尔曼滤波通过利用过去的观测值和系统模型,对当前状态进行估计和观测,然后利用当前状态的观测值,对通过最小化估计误差的方法对预测值进行修正和更新。

SORT^[20]算法是最早的基于检测的跟踪算法之一,使用了 Faster R-CNN^[21]来进行目

标检测,得到目标的位置坐标和大小,然后使用卡尔曼滤波得到目标预测框,得到的检测框与跟踪框使用基于 IOU 的较高效率的匈牙利匹配算法,得到跟踪结果。DeepSORT^[22]算法在 SORT 算法的基础上增加了级联匹配和新轨迹的确认。DeepSORT 将卡尔曼滤波得到的预测框和目标检测模型得到的检测框使用匈牙利匹配算法进行级联匹配和 IOU 匹配,然后进行卡尔曼滤波更新。

BoT-SORT^[23]是对 DeepSORT 的改进版本,使用 YOLOX^[24]作为检测器,更快更准,可以处理小目标和密集场景;BoT 作为特征提取器,可以提取更丰富的外观特征;使用 GMC 技术进行相机运动补偿,减少误匹配和漏匹配。而 StrongSORT^[25]是对 BoT-SORT 的各个组成部分进行升级,使用 ECC 算法校正相机视角的变化,被广泛用于补偿 MOT 任务中相机移动引起的运动噪声;提出了基于外观无关的全局关联模型 AFLink 和基于高斯平滑插值 GSI 解决 MOT 中的缺失问题;使用 NSA 卡尔曼滤波,能更好的适应目标的运动变化。

OC-SORT^[26]是一种基于纯运动模型的多目标跟踪器,旨在提高拥挤场景中的跟踪鲁棒性,以及在目标处于非线性运动时的跟踪鲁棒性。提出了一种以观测为中心的平滑策略,以减少误差累积。具体地,当一个不活跃的轨迹需要重新识别时,它会为这个轨迹建立一个虚拟轨迹。虚拟轨迹的起点是它上一次被发现的位置,终点是它再次被发现的位置,在这两个位置之间进行平滑。此外,在代价矩阵中加入了轨迹方向的一致性,证明了对相隔较大的两点之间的方向进行估计可以减少噪声。为了减少目标在短时间内由于遮挡而变为不活跃的问题,作者提出了一种根据它们新旧观测进行恢复的策略。Deep OC-SORT^[27]在 OC-SORT 的基础上,通过自适应重新识别来利用目标的外观来自适应地将外观匹配集成到现有的高性能基于运动的方法中。它使用了一个已经训练过的 re-ID 模型,能够在大规模的 re-ID 数据集上区分行人。Deep OC-SORT 在 OC-SORT 的基础上增加了对外观信息的利用,以提高多目标跟踪的性能。

ByteTrack^[28]也是一种基于检测的跟踪方法,提出了一种简单高效的数据关联方法 BYTE。它与之前的跟踪算法的最大区别在于,并不是简单地去掉低分检测结果,而是通过检测框和跟踪轨迹之间的相似性,在保留高分检测结果的同时,从低分检测结果中去除背景,保留一些难以跟踪的目标,从而降低漏检并提高轨迹的连贯性。该算法速度很快,各项指标均有突破。

TubeTK^[29]提出了一个简洁的端到端的多目标跟踪模型,只需要一步训练,通过引入“边界管”来表示短视频片段中物体的时空位置。TubeTK 提供了一个新颖的多目标跟踪的方向,并且证明了它在没有任何额外技术的情况下,可以解决一些挑战,例如利用视频的时空信息,处理物体的遮挡,减少对检测结果的依赖等。显示 TubeTK 有一定的能力在不使用 Re-ID 等技术的情况下克服遮挡。

JDE^[30]提出了联合跟踪检测系统,该系统允许在共享模型中学习目标检测和外观嵌入。具体而言,将外观嵌入模型合并到检测器中,使得该模型可以同时输出检测结果和相应的嵌入。该系统被表述为一个多任务学习问题,检测任务和外观嵌入学习任务,并自动平衡这两个任务的 loss。

CenterTrack^[31]受到 JDE 的启发,通过将 Faster R-CNN 变换为基于无锚框模式的 CenterNet^[32]。设计了一种多目标跟踪算法,将多目标跟踪问题转化为非常简单的基于目标中心点的跟踪,同时实现了二维和三维多目标跟踪,包括人和车辆,但是其局限性在于 CenterTrack 并未提取重识别特征,在目标长时丢失情况下 IDs 情况较多。

FairMOT^[33]算法是一种一阶段的 MOT 方法,它将目标检测和 re-ID 在一个单一的神经网络中进行联合优化,也使用了 CenterNet,并在此基础上加了一个 re-ID 分支,用于提取目标的外观特征。为了保证检测和 re-ID 两个任务的公平性,需要平衡这两个任务的 loss。并且在联合检测和跟踪模式中,更适合低维度的 re-ID 特征,提高检测精度,推理速度更快。使用了 DLA 多尺度特征融合,提高特征的表达能力。

1.2.3 时间序列模型的研究进展

时间序列模型^[34]是用于分析和预测按时间顺序排列的数据点的统计模型。这些模型可以帮助我们理解过去的行为,并预测未来的趋势。时间序列模型通常可以分为以下几类^[35]:

(1) 基于线性模型的时间序列模型:该类模型用于捕捉时间序列的整体趋势和周期性变化和随机波动。

(2) 基于 RNN^[36]的时间序列模型:递归神经网络(RNN)是一种人工神经网络,能够处理时序数据。RNN 模型可以捕捉时间序列数据之间的依赖关系,并预测未来的时间序列数据。

(3) 基于 Transformer^[37]的时间序列模型:Transformer 是一种依赖注意力机制的深度学习模型。Transformer 模型可以捕捉时间序列数据的长距离依赖关系,并用于预测未来的值。

LSTM^[38]是一种基于循环神经网络的长短期记忆模型,可以通过门控机制来存储和遗忘历史信息,从而解决长期依赖问题。而 GRU^[39]对 LSTM 进行了改进,是一种简化的 LSTM 模型,可以通过重置门和更新门来控制信息的流动,减少了参数数量和计算复杂度。

随着 Transformer 在深度学习各大领域中的普及,也应用在了时间序列模型中。Informer^[40]就是一种基于 Transformer 的模型,可以通过自注意力机制来捕捉时间序列的长期依赖和全局特征,同时引入了概率编码和注意力分解来提高预测的不确定性和效率。

Autoformer^[41]在此基础上进行改进,通过自适应的位置编码和自适应的注意力机制来适应不同的时间序列数据,同时利用了残差连接和层归一化来增强模型的稳定性和泛化能力。Pyraformer^[42]则是在 Informer 的基础上,通过多层次的注意力机制来实现多尺度的时间序列预测,同时利用了卷积神经网络和稀疏注意力来降低模型的计算开销和内存消耗。FEDformer^[43]将时间序列数据分解为不同的特征子空间来提高模型的表达能力和预测精度,同时利用了多任务学习和注意力蒸馏来增强模型的泛化能力和效率。PatchTST^[44]可以通过将时间序列数据转换为图像块来实现时间序列的长期预测,同时利用了卷积神经网络和 Transformer 来提取图像块的局部和全局特征。PatchTST 在多个时间序列预测数据集上取得了最佳的效果,超越了其他的深度学习模型,如 LSTM、GRU、Informer、Autoformer 等。

与基于 RNN 或者 Transformer 不同的还有线性模型。LTSF-Linear^[45]是通过一个线性层来实现时间序列的长期预测,同时利用了数据分解、归一化和混合专家等技巧来处理时间序列的非平稳性和非线性性。但从本文实际实验中看线性模型的效果不如神经网络模型。

1.3 研究内容

本文选题来自国家重点研发计划:“设施水产养殖智能化精细生产管理技术装备研发”,课题编号 2017YFD0701700。本课题是基于计算机视觉的鱼类活跃度分类模型研究,在真实水产养殖基地中确定研究方案,搭建实验平台,通过水下摄像头采集数据建立鱼类活跃度分类数据集,建立基于计算机视觉的多目标跟踪模型 YO-BYNet 来实现对鱼的轨迹提取、游速计算,构建鱼类活跃度特征序列,进一步建立鱼类活跃度分类模型 FAC-Net,对鱼类活跃度进行二分类并将结果在鱼类福利养殖监测系统中显示。图 1.1 为技术路线图。

主要研究内容为:

- 1.制作鱼类的活跃度分类数据集。实验团队与国内领先的大西洋鲑养殖公司合作,主要以工厂化循环水养殖环境下的大西洋鲑作为研究对象,通过水下摄像机获取大西洋鲑行为视频数据,将视频切分抽帧标注制作为鱼类多目标检测数据集用于 YO-BYNet 的检测器训练,将每帧标注 ID 制作为鱼类多目标跟踪数据集用于 YO-BYNet 的跟踪器训练,将 YO-BYNet 获取的活跃度特征序列制作成鱼类活跃度分类数据集用于 FAC-Net 的分类训练。

- 2.结合实验优化结果,提出了一个能实现良好准确度和较快速度的鱼类多目标跟踪任务的模型 YO-BYNet。YO-BYNet 是一个基于目标检测的鱼类多目标跟踪模型,将 YOLOv8 作为检测器检测出每一帧多条鱼的位置和大小,卡尔曼滤波和 BYTE 关联方法

结合起来作为跟踪器对每个目标赋予 ID，并加入了 NSGA-II^[46]遗传算法对跟踪器进行多目标优化。

3.建立鱼类活跃度分类模型 FAC-Net, 包括 YO-BYNet 和其生成的活跃度特征序列, 结合基于 Transformer 的时间序列模型 PatchTST 和分类器对鱼类活跃度等级进行二分类, 分为活跃和不活跃两类。

4.建立了一个鱼类福利养殖监测系统, 使用了本文提出的鱼类活跃度分类模型 FAC-Net 进行鱼类活跃度分类并展示分类结果, 若有其他传感器数据也可通过该系统进行监测显示, 并能自动对分类结果和其他数据进行记录。对于养殖人员, 该系统能够起到很好的辅助作用。




图 1.1 技术路线图

1.4 组织结构

本文基于工厂化循环水养殖的真实环境, 研究对象为大西洋鲑, 通过水下摄像头的

方式开展鱼类活跃度分类模型研究。本文一共 6 章，各个章节的主要内容如下：

第 1 章：绪论。本章节主要是研究背景及意义的介绍，对鱼类活跃度、多目标跟踪算法、时间序列模型三个方向进行国内外研究现状分析，总结了本文的主要研究内容和组织结构。

第 2 章：数据采集系统与数据集构建。本章节介绍了本文工作的研究环境和工厂化养殖基地的具体情况，根据实际的试验环境设计了水下视角鱼类活跃度视频采集方案，进行视频数据的采集，最后经过分割、抽帧、预处理、标注等工作完成数据集的制作。介绍了鱼类活跃度数据集构建的具体过程和数据集分析内容。

第 3 章：基于目标检测的鱼类多目标跟踪模型 YO-BYNet。本章节主要介绍了 YO-BYNet 的模型结构和原理，还有多目标跟踪算法相关的评估指标。运用该模型对数据集进行多目标跟踪，展示实验结果，并且通过对比实验来说明改进部分的有效性。

第 4 章：鱼类活跃度分类模型 FAC-Net。本章节主要介绍了该模型的基本结构，如何将第 3 章的 YO-BYNet 与基于 Transformer 的时序模型 PatchTST 和分类器结合起来，实现鱼类活跃度的分类。介绍了分类的评估指标和运用该模型的实验结果，并进行对比实验来证明其有效性。

第 5 章：鱼类福利养殖监测系统。本章节基于工厂化循环水养殖的设计一套鱼类福利养殖监测系统。通过水下摄像头采集传输数据，使用本文提出的 FAC-Net 鱼类活跃度分类模型，实现鱼类福利养殖监测系统，可为养殖人员提供鱼类福利养殖的辅助监测。

第 6 章：总结与展望。对本文总体的工作内容进行总结，并且提出本文的工作内容的不足之处和可以继续改进的地方，对后续的研究进行展望。

1.5 本章小结

本章首先对简述了本研究的研究背景及意义，简述了鱼类福利养殖，然后对国内研究现状进行分析，分为鱼类活跃度、多目标跟踪算法、时间序列模型三大部分。之后简述了本文的主要内容，分为建立鱼类活跃度分类数据集、建立鱼类多目标跟踪模型 YO-BYNet、建立鱼类活跃度分类模型 FAC-Net、建立鱼类福利养殖监测系统四个部分。最后介绍了本文的技术路线和组织结构。

2 数据集采集系统与数据集构建

本章主要详细介绍了采集与制作鱼类活跃度分类数据集的过程，主要包括搭建数据采集系统，采集原始视频数据，后期数据处理方式等内容。鱼类活跃度分类数据集主要包括用于训练检测器的鱼类多目标检测数据集，用于训练跟踪器的鱼类多目标跟踪数据集，用于训练鱼类活跃度分类模型的鱼类活跃度数据集。

2.1 数据采集基地介绍

数据采集基地为山东东方海洋科技股份有限公司，采集对象为大西洋鲑，该公司是国内知名的工厂化循环水养殖大西洋鲑基地，如图 2.1 所示为该公司的工厂化循环水养殖池。其在商业化养殖的同时还与多个研究所和高校达成了战略合作协议，公司能为研究人员提供采集数据的真实养殖环境。养殖大西洋鲑的水质较好，通过摄像头能够较好的观测到它的活跃度。数据采集的循环养殖池如图所示，循环养殖池水深 1.8m，平均半径为 4m，容积约为 90m³，溶解氧浓度约为 10-12mg/L。研究对象为大西洋鲑，鱼体长约为 40-50cm，每条鱼平均质量约为 2kg，大西洋鲑在该池的饲养量约为 700 尾，养殖密度约为 7.5 尾/m³。



图 2.1 工厂化循环水养殖池

2.2 数据采集方案设计

由于工厂化循环水养殖的室内环境光源较多，如若在水上设置摄像头，摄像头会拍摄到大量的水面反光，因此，本文考虑在水下设置摄像头采集视频。大西洋鲑实际上会在整个养殖池里集体循环游动，在实验器材有限的情况下，将摄像头拍摄的一部分鱼代表整个鱼群具有一定可行性的。每个养殖池的尺寸大小基本相同，如果将摄像机都固定在同一位置，摄像机能拍摄到的视频情况也是基本一致的。循环水养殖厂中每个养殖池的水质都相近，透光程度相近，对一个养殖池进行实验得到的鱼类活跃度分类方法到其他养殖池使用依然可行。

本文拍摄设备选用 GoPro Hero 7 Black 运动防水相机，1200 万像素，能够较清晰的拍摄到大西洋鲑，观测其活跃度，支持拍摄 4K 60 帧视频，大西洋鲑的游动速度较快，需要较高帧率才能更清晰的记录其实际游动情况。支持电子防抖和 10m 防水功能，电子防抖可以在数据采集时减小拍摄画面的抖动，防水功能可以支持在循环养殖池内拍摄视频。

如图 2.2 所示，本文将摄像机通过 Z 字形支架布置到水下进行摄影。结合实际测试实验，最终选定摄像机架设在离养殖池底 0.4m 高度，并且选取相机仰角 5.9 度用于拍摄，如图 2.3 所示。考虑到存储设备的局限，最终选用分辨率为 2704*1520 和 30 帧率的格式来存储视频。



图 2.2 摄像机架设场景




图 2.3 摄像机架设示意图

2.3 鱼类活跃度分类数据集构建

本文采集了工厂化循环水养殖大西洋鲑的视频，该视频旨在尽可能多的包含鱼的行为状态，收集了在各个时段投喂和增氧等状态下鱼的运动视频。包括从视频每隔 10 帧抽一帧的 5130 张分辨率为 2704×1520 的图片用于训练检测器，总共的目标数有 56648 个，平均每张图片数为 11 个左右。10 个 30FPS 的时长 10s 的分辨率为 2704×1520 的视频用于跟踪器的训练。

另外每 10s 切分一次视频，除去一些无效视频，将剩下的 365 个视频进行活跃度二分类，分为活跃和不活跃两类用于活跃度分类模型的训练。以上数据集划分训练集、验证集、测试集的比例皆为 7:2:1，关于该数据集的详细信息见表 2.1。

鱼类活跃度的分类以大西洋鲑为研究对象，主要结合养殖技术人员的经验判断以及鱼的运动状态例如正常巡游，缓慢游动，静止不动等来综合分析。如若需要进行其他品种的鱼活跃度分类，需结合养殖人员经验以及其他鱼的特性来进行分析。

本文采用了 DarkLabel 工具标注图片和视频，标注的标签包括边界框位置和大小和鱼的类别和鱼相应的 id。对于部分遮挡的目标，我们会用完整的边界框对它进行标注；对于完全遮挡的目标，我们不会标注它，直到它重新出现在未来的帧中，赋予它和被遮挡之前相同的 id。为了使标注过程更加简洁，工具会将当前帧的标注传至下一帧中，在下一帧中作相应的调整即可。

该数据集的难点在于光线不充足，水中杂质较多，因此图片中的噪点较多影响模型对背景和目标的区分；鱼游动的速度不一致，会导致不同程度的动态模糊，影响检测器对鱼的外观特征提取；鱼游动通常是不规律的，非线性的，对跟踪器是个很大的挑战；养殖鱼密度较大，遮挡现象十分常见，对模型的泛化能力和鲁棒性的要求较高；鱼由于个体导致的外观差异，需要检测器具有一定的泛化能力；鱼游动时的形态差异较大，需要检测器良好的泛化能力和特征提取能力。

表 2.1 本文建立的数据集的信息详细表

数据集名称	数据集格式	标注格式	训练集数量	验证集数量	测试集数量
鱼类多目标检测数据集	JPG	YOLO	3591	1026	513
鱼类多目标跟踪数据集	JPG	MOT	2100	600	300
鱼类活跃度分类数据集	CSV	时间序列	76650	21900	15950

2.3.1 鱼类多目标检测数据集构建

本文构建了鱼类多目标检测数据集用于 YO-BYNet 的检测器的训练，标注方式和其他多目标检测数据集类似，用矩形框出目标，仅选取边缘清晰的人眼可分辨的鱼，过于模糊不清难以辨认的不进行标注，如图 2.4 所示。本文将采集的水下鱼类视频每间隔 10 帧抽一帧作为多目标检测的数据集。该数据集共计 5130 张，每张图片为 JPG 格式，分辨率为 2704*1520，给每张图片命名为六位编号，标注的格式为 YOLO。YOLO 标注格式的第一列为类别编号，剩余数据为位置坐标 x，y，长宽 w，h。




图 2.4 鱼类多目标检测数据集标注

2.3.2 鱼类多目标跟踪数据集构建

本文构建了鱼类多目标跟踪数据集用于 YO-BYNet 的跟踪器的训练，标注方式和多目标跟踪数据集 MOTChallenge^[47]类似，用不同颜色的矩形框出不同的目标，在帧之间给不同的目标按顺序赋予不同的 ID，相同的目标赋予相同的 ID，如图 2.5 所示。本文将采集的水下鱼类视频切分成每 10s 一个的视频，然后每个视频都进行抽帧。该数据集共有 10 个视频，每个视频长度为 10s，分辨率为 2704*1520，每个视频有 300 帧，标注格式为 MOT。数据格式为帧数，鱼的 ID，每条鱼的 x，y 位置坐标，长宽 w，h，置信度，类别编号，可见程度。



图 2.5 鱼类多目标跟踪数据集标注

2.3.3 鱼类活跃度分类数据集构建

本文构建了鱼类活跃度分类数据集用于 FAC-Net 的训练，该数据集格式与 Autoformer 和其他时间序列模型所采用的数据集格式类似。本文首先将采集的养殖池视频切分成每 10s 的视频，再将这些视频进行二分类，分为活跃和不活跃。接着将切分好的视频输入到 YO-BYNet，从而得到鱼类多目标跟踪结果。本文将鱼类多目标跟踪结果保留 ID，位置坐标，并根据 ID 和位置坐标计算每条鱼的游速，作为活跃度特征序列。将活跃度特征序列和活跃度分类标签一起保存到 csv 文件中。值得注意的是，由于需要输入到 PatchTST 中，这一类模型需要的时间数据不是帧数，需要的是年月日时分的时间格式。因此需要将帧数乘以 15 分钟再以年月日时分的格式进行表示存入到 csv 中。该数据集的制作流程如图 2.6 所示。该数据集使用了 171 个活跃视频和 194 个不活跃视频，数据集中的条数为 109500 条。




图 2.6 鱼类活跃度分类数据集制作流程

2.4 本章小结

本章主要介绍了数据采集基地、数据采集方案设计、鱼类活跃度分类数据集的建立过程。首先对数据采集基地进行调研和分析，确定数据采集方案，进行实施，然后根据采集的视频进行具体的数据集制作，分为鱼类多目标检测数据集、鱼类多目标跟踪数据集、鱼类活跃度分类数据集三部分，最后完成总结统计。

3 基于目标检测的鱼类多目标跟踪模型 YO-BYNet

3.1 YO-BYNet 模型结构




图 3.1 YO-BYNet 的模型结构

YO-BYNet 模型结构如图 3.1 所示，本文将 YOLOv8，卡尔曼滤波器，BYTE 关联方法，NSGA-II 遗传算法结合起来形成了 YO-BYNet 模型。视频当前帧 t 输入到卡尔曼滤波器和 YOLOv8 检测器中，从卡尔曼滤波器中根据前面 $t-1$ 帧的运动特征输出当前帧 t 的跟踪框，从检测器中输出当前帧 t 的检测框。然后通过 BYTE 关联方法，第一轮先关联高分的检测框与跟踪框，第二轮关联低分的检测框与跟踪框，然后输出关联成功的跟踪轨迹，同时使用 NSGA-II 遗传算法对关联方法的参数进行调整优化。

3.1.1 YO-BYNet 检测器

YO-BYNet 检测器主体为 YOLOv8^[48]，模型结构如图 3.2 所示，是一个全新的 SOTA 模型，包括 640 和 1280 分辨率的目标检测网络。YOLOv8 的主要结构是将 CSPDarknet^[49] 作为 Backbone、PAFPN^[50] 作为 Neck、解耦头和检测头分类头作为 Head。

由于鱼类多目标跟踪数据集提供的图片分辨率较高，水下摄影噪点较多，我们将 YOLOv8 的图片分辨率输入设定为 1280，检测效果会更好。YOLOv8 为了满足不同场景需求，提供了 N/S/M/L/X 不同尺度的模型。我们需要实现鱼类多目标跟踪任务，需要兼顾速度与性能，选择了 M 尺度的模型。同时 YOLOv8 也从 Anchor-Based 换成了 Anchor-Free。我们认为 Anchor-Free 比 Anchor-Based 更适合训练鱼类的多目标跟踪数据集，在特征图上直接预测目标的边界框，可以更好的处理不同尺度和形状的鱼。Anchor-Free 不需要预设 anchor 的尺寸、长宽比和数量，简化了网络结构和超参数的选择。不需要对

anchor 进行非极大值抑制，减少了后处理的复杂度。训练过程中我们将 patience 设置成 50，patience 设置过大时会发生过拟合现象，导致检测效果不增反降。




图 3.2 YO-BYNet 检测器模型结构

Backbone 骨干网络负责从输入图像中提取有意义的特征。它在初始层抽取简单的特征，例如边缘和纹理，并随着网络深入提取不同级别的特征，提供丰富的层次化特征。YOLOv8 的 **Backbone** 骨干网络是基于 CSPDarknet 的卷积神经网络架构。CSPDarknet 的主要特点是它采用了 CSPNet^[51]策略，这个策略将基层特征图分为两部分，然后通过跨阶段层次结构合并它们。这种分割和合并的策略允许更多的梯度流通过网络，从而提高了模型的性能。YOLOv8 将其中 YOLOv5 的 C3 结构换成了梯度流更丰富的 C2f 结构，并对不同尺度模型调整了不同的通道数，大幅提升了模型性能。

Neck 作为 **Backbone** 和 **Head** 之间的桥梁，执行特征融合操作并整合上下文信息。**Neck** 通过聚合 **Backbone** 阶段的特征图来组装特征金字塔，确保网络能够检测不同大小的目标。YOLOv8 的 **neck** 部分为 PAFPN 结构，如图 3.3 所示，即金字塔注意力特征金字塔网络(Pyramid Attention Feature Pyramid Network)，是一种用于目标检测的网络结构，能通过特征融合和上下文信息整合来提高检测的准确性和速度。




图 3.3 PAFPN 结构

Head 是网络的最终部分,负责生成网络输出,如目标检测的边界框和置信度分数。它生成与图像中可能目标相关联的边界框,并为每个边界框分配置信度分数,以指示目标存在的可能性。YOLOv8 的 Head 部分相比 YOLOv5 改动较大,换成了目前主流的解耦头结构,将分类和检测头分离。

YOLOv8 的 Loss 计算包括两个阶段,第一个阶段是正样本分配策略 Loss Task Aligned Assigner^[52],通过对每个锚点(anchor)进行评估,计算其与真实边界框(ground truth boxes)之间的重叠度(IoU)以及预测的分类和回归损失,选择那些最有可能代表真实目标的锚点作为正样本,使用这些样本来计算损失,并通过反向传播来优化模型权重。该策略有助于模型更准确地识别和定位各种尺寸和形状的目标,特别是在存在类别不平衡或复杂背景的情况下。第二个阶段是包括两个分支:分类分支和回归分支。分类分支采用了 BCE loss(Binary Cross Entropy)^[53],是一种机器学习中常用的损失函数,它计算目标值和预测值之间的交叉熵,用于评估模型的准确性。它的计算公式如(3.1)所示,其中 N 是样本数量, p_i 是模型预测第 i 个样本为类别 1 的概率, y_i 是第 i 个样本的实际标签,其值为 0 或 1:

$$BCE\ Loss = -\frac{1}{N} \sum_{i=1}^N \left[y_i \cdot \log(p_i) + (1 - y_i) \cdot \log(1 - p_i) \right] \quad (3.1)$$

回归分支采用了 Distribution Focal Loss^[54]和 CIoU^[55]。Distribution Focal Loss 通过将回归目标量化为多个区间,然后将目标表示为这些区间上的积分。这种方法使得模型能够更精确的预测边界框的位置,因为它不仅考虑了单一的预测值,而是考虑了一个预测值的范围。这种损失函数对于改善模型在检测稀有目标时的性能特别有效,因为它通过关注那些难以正确预测的样本来解决类别不平衡问题。计算公式如(3.2)所示,其中 c 是类别的总数, α_c 是针对第 c 类别的权重, p_i^c 是模型预测第 c 类别的概率, γ 是调整易分类样本权重的聚焦参数:

$$DFL = \sum_{c=1}^c -\alpha_c (1-p_t^c) \gamma \log(p_t^c) \quad (3.2)$$

CIoU是完整交并比(Complete Intersection over Union),是IoU损失函数的一种改进,不仅考虑了边界框的重叠区域,还包括了中心点距离和长宽比的一致性。公式如(3.3)所示,其中IoU是交并比, $\rho(b, b_{gt})$ 是预测框 b 和真实框 b_{gt} 中心点之间的欧氏距离, c 是包含预测框和真实框的最小闭合区域的对角线长度, α 是一个权重参数,用于平衡长宽比项, v 是一个用于衡量预测框和真实框长宽比一致性的项。

$$CIoU = IoU - \frac{\rho^2(b, b_{gt})}{c^2} - \alpha \cdot v \quad (3.3)$$

CIoU损失通过这些项来更全面的衡量预测框和真实框之间的差异,从而在训练中提供更精确的梯度信息。YOLOv8的数据增强部分引入了YOLOX中的最后10 epoch关闭Mosaic增强的操作,可以有效地提升精度。

3.1.2 YO-BYNet 跟踪器

YO-BYNet跟踪器部分由卡尔曼滤波器(Kalman Filter)和BYTE关联方法组成。我们利用卡尔曼滤波器生成跟踪框,BYTE关联方法进行跟踪框与检测框的匹配。由于鱼类在水下游动时,有严重的运动模糊,运动规律非线性程度高,所以跟踪器无法使用re-ID模型,也无法使用其外观特征,跟踪器将主要根据运动特征进行跟踪。因此我们使用基于运动模型的卡尔曼滤波器对多条鱼进行跟踪框的预测,它可以同时处理多条鱼的状态,根据输入模型的每一帧图片逐帧生成多条鱼对应的跟踪框。它的基本流程如图3.4所示:

卡尔曼滤波的过程通常包括两个主要阶段:预测和更新。首先进行初始化,确定初始状态估计值和初始误差协方差矩阵。在本文中状态估计值主要是鱼的边界框的中心位置 (x, y) 长宽比 a ,高度 h 。接下来是预测阶段,分为状态预测和协方差预测。状态预测是基于这一时刻的状态估计值根据系统的运动模型预测鱼下一时刻的状态,公式如(3.4)所示,其中 F_k 是状态转移矩阵, B_k 是控制输入矩阵, u_k 是控制向量:

$$\hat{x}_{k|k-1} = F_k \hat{x}_{k-1|k-1} + B_k u_k \quad (3.4)$$

协方差预测是根据这一时刻的误差协方差预测下一时刻的误差协方差,公式如(3.5)所示,其中 Q_k 是过程噪声协方差矩阵:

$$P_{k|k-1} = F_k P_{k-1|k-1} F_k' + Q_k \quad (3.5)$$

然后是更新阶段,先进行观测更新,获取新的测量数据,结合状态预测值根据观测残差公式算出观测残差。观测残差公式如(3.6)所示,其中 z_k 是实际测量值, H_k 是观测矩阵:

$$y_k = z_k - H_k \hat{x}_{k|k-1} \quad (3.6)$$

然后根据状态预测值和协方差预测值,计算卡尔曼增益,它决定了预测和测量之间的权重。卡尔曼增益计算公式如(3.7)所示,其中 R_k 是测量噪声协方差矩阵:

$$K_k = P_{k|k-1} H_k^T (H_k P_{k|k-1} H_k^T + R_k)^{-1} \quad (3.7)$$

再利用卡尔曼增益，状态预测值，观测残差，更新状态估计值。公式如(3.8)所示：

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k y_k \quad (3.8)$$

最后通过卡尔曼增益，观测矩阵进行协方差更新，其中 I 是单位矩阵，公式如(3.9)所示：

$$P_{k|k} = (I - K_k H_k) P_{k|k-1} \quad (3.9)$$




图 3.4 卡尔曼滤波流程图

卡尔曼滤波的优点主要包括：卡尔曼滤波是一种最优滤波器，它能够有效地消除测量噪声和抖动，提供最小的均方误差。它不仅可以估计系统状态，还可以估计状态的协方差，增加了对系统不确定性的鲁棒性。卡尔曼滤波可以实时进行状态估计，响应速度快，适用于需要快速反应的系统。这些特性使得其适合需要实时、准确的状态估计的水下鱼类多目标跟踪任务。

大多数多目标跟踪关联方法通过关联分数高于阈值的检测框来获取目标 ID。对于检测分数较低的目标，例如鱼之间的互相遮挡，会被简单的丢弃，这带来了不可忽略的问题，包括大量的漏检和碎片化轨迹。我们为了解决该问题，使用一种简单、高效且通用的数据关联方法 BYTE，通过关联每个检测框而不仅仅是高分检测框来进行跟踪。对

于低分检测框,利用它们与轨迹的相似性来恢复真实目标并过滤掉背景。它无需使用 Re-ID 模型,使用匈牙利算法根据 IoU 进行相似度匹配。

根据下图 3.5, BYTE 关联方法的具体流程步骤是:

初始化: 通过 YO-BYNet 检测器获取检测框和对应的置信度,对检测框进行分类。如果置信度高于检测框置信度分类阈值,则将检测框分类为高置信度组;置信度低于检测框置信度分类阈值但高于一定置信度时,将检测框分类为低置信度组。

第一次匹配: 使用 YO-BYNet 检测器生成的检测框的高置信度组与卡尔曼滤波器生成的跟踪框之间的 IoU 特征间距离作为相似度度量,然后基于相似度采用匈牙利算法进行匹配。保留未匹配到跟踪框的高置信度检测框以及未匹配到检测框的跟踪框。

第二次匹配: 关联第一次匹配剩下的跟踪框以及低置信度检测框,同样是基于相似度进行匈牙利算法匹配。删除在第二次匹配过后未找到对应跟踪框的低置信度检测框,因为这些检测框被认定为背景。

跟踪框更新: 将未匹配到对应跟踪框的高置信度检测框初始化成新的跟踪框。




图 3.5 BYTE 关联方法流程

3.1.3 结合 NSGA-II 遗传算法微调跟踪器

YO-BYNet 的跟踪器包括卡尔曼滤波和关联方法 BYTE。我们将跟踪器结合 NSGA-II 进行微调,为特定跟踪方法的超参数和特定数据集进行多目标优化,最终输出最佳超参数集。在 YO-BYNet 中 NSGA-II 演化的超参数主要是:相似度匹配的阈值,使用余弦相似度来计算两个数据点是否足够相似以被认为是同一个目标;检测框分类的阈值,用于决定何时开始跟踪一个目标,如果目标的置信度高于此阈值,它将被认为是一个有效的跟踪目标;保留跟踪框的阈值,指定了跟踪器保持跟踪信息的帧数,如果一个目标在制定帧数内没有被再次检测到,它将被认为是丢失的。

我们使用 optuna^[56]库进行超参数优化,它是一个开源的专为机器学习设计的自动超参数优化软件框架。我们进行超参数优化时指定试验次数和回调函数,会自动测试不同的超参数组合,然后将得到最佳 HOTA 评分的试验中的超参数写入跟踪器的配置文件中。

NSGA-II 是一种目前最流行的多目标优化算法之一,它降低了非劣排序遗传算法的复杂性,具有运行速度快,解集的收敛性好的优点,成为其他多目标优化算法性能的基准。它的过程可以概括为以下几个步骤:

初始化:随机生成一个初始种群,种群指上述 BYTE 关联方法的超参数集合。

非支配排序:将种群中的个体根据支配关系分层排序。每一层被称为一个“前沿”(front),第一层是当前种群中所有非支配解的集合,称为 Pareto 前沿。

拥挤度计算:在每个前沿内部,计算个体的拥挤度,以保持种群的多样性。

选择:使用二元锦标赛选择(binary tournament selection)基于非支配排序和拥挤度来选择个体进行繁殖。

交叉和变异:对选中的个体进行交叉和变异操作,产生新的后代。

合并和选择:将父代和子代合并,再次进行非支配排序和拥挤度计算,然后选择出新的种群。

精英策略:确保高质量的个体能够被保留到下一代。

这个过程会重复进行,直到满足终止条件,如达到预定的进化代数或解的质量。

3.2 实验结果分析

3.2.1 评价指标

多目标跟踪模型主要使用 HOTA^[57], MOTA^[58], IDF1, AssA, DetA 作为评估的指标。HOTA 在多个流行的基准测试中已作为主要指标来评估跟踪质量,比起更关注检测质量而不是关联质量的 MOTA 有显著优势。MOTA 旨在表示多目标跟踪的准确度,

体现在确定目标的个数，以及有关目标的相关属性方面的准确度，用于统计在跟踪中的误差积累情况。IDF1 指标代表被检测和跟踪的目标中获取正确的 ID 的检测目标的比例，综合考虑 ID 准确率和 ID 召回率，代表两者的调和均值。AssA 为关联的准确率，评价关联的准确率。DetA 为跟踪框的准确率，评价多目标跟踪中检测器与跟踪器的综合性能。引用了 TrackEval 工具包，进行多目标跟踪模型的全方位评估。

HOTA 的计算公式如下，其中 TP 是正确检测到的目标数量，FP 是错误未检测到的非目标数量，FN 是未检测到的目标数量，A(c)表示给定的 TP 中，预测的 ID 和 GT 的 ID 都为 c 的情况，c 代表一个特定的目标的 ID，实际上是考虑了特定 ID 的所有正确关联和错误关联的比例，从而提供了一个关于跟踪准确性的度量。TPA(c)是预测的 ID 和 GT 的 ID 都为 c 的数量。FNA(c)是 TP 中，预测的 ID 为 c，GT 不为 c 的数量，以及 FN 中，预测 ID 为 c 的数量。FPA(c)是 TP 中，预测的 ID 为 c，GT 不为 c 的数量，以及 FP 中预测的 ID 为 c 的数量。先计算(3.11)的 A(c)，再将(3.11)的结果代入(3.10)计算出 $HOTA_{\alpha}$ ，再将 $HOTA_{\alpha}$ 代入(3.12)积分得出 HOTA：

$$HOTA_{\alpha} = \sqrt{\frac{\sum_{c \in \{TP\}} A(c)}{|TP| + |FN| + |FP|}} \quad (3.10)$$

$$A(c) = \frac{|TPA(c)|}{|TPA(c)| + |FNA(c)| + |FPA(c)|} \quad (3.11)$$

$$HOTA = \int_0^1 HOTA_{\alpha} d\alpha \approx \frac{1}{19} \sum_{\alpha \in \left\{ \begin{smallmatrix} 0.05, 0.1, \dots \\ 0.9, 0.95 \end{smallmatrix} \right\}} HOTA_{\alpha} \quad (3.12)$$

3.2.2 实验结果

表 3.1 各个规模的 YOLOv8 模型在本文鱼类多目标检测数据集下的表现

Detector	Params	FLOPs	Size	FPS↑	AP↑	AP ₅₀ ↑
YOLOv8n	3.2M	8.7	1280	130	87.0	93.0
YOLOv8s	11.2M	28.6	1280	125	91.3	93.7
YOLOv8m	25.9M	78.9	1280	83	97.1	98.3
YOLOv8l	43.7M	165.2	1280	53	95.9	96.5
YOLOv8x	68.2M	257.8	1280	40	97.0	98.1

本文所有的模型实验运行环境都一致，服务器的操作系统为 Ubuntu20.04.4，CPU 为两颗 20 核 40 线程的 Intel(R) Xeon(R) CPU E5-2698 v4 @ 2.20GHz，运行内存为 256G，GPU 为三张 40G 显存的英伟达 A100。

本实验对比了各个规模的 YOLOv8 模型在本文建立的鱼类多目标检测数据集下的表现。从表 3.1 中可以看出 YOLOv8n 属于轻量化模型，用的算力很少，FPS 高，但相

对于其他规模，准确度明显低很多。YOLOv8m 相较于 YOLOv8s，AP 高很多，可以看出鱼类的多目标跟踪任务更适合规模大一些模型。由于需要跟踪的鱼类品种和环境单一，所以 YOLOv8m 的规模已经基本能满足任务需求。YOLOv8l 和 x 规模的模型 AP 不如 YOLOv8m 高，可能是模型规模过大，现有数据集的规模无法满足大规模模型的训练。大规模模型参数量和算力需求较高，推理速度相对较慢，训练时间也长很多。综上所述，YOLOv8m 较适合作为 YO-BYNet 的检测器。图 3.6 为 YO-BYNet 的多目标检测结果可视化。




图 3.6 YO-BYNet 的多目标检测结果可视化

表 3.2 不同跟踪器在本文鱼类多目标跟踪数据集集中的表现

Tracker	HOTA↑	MOTA↑	IDF1↑	AssA↑	DetA↑	FPS↑
Deep OC-SORT	60.9	60.7	40.8	67.5	55.1	10
BoT-SORT	64.8	61.2	44.7	73.2	57.3	31
StrongSORT	58.5	57.6	42.5	64.1	53.4	25
OC-SORT	63.3	61.0	41.5	70.5	56.8	22
BYTE	74.8	58.2	38.7	81.6	68.6	40

本文以表 3.1 中的 YOLOv8m 作为检测器，将 YO-BYNet 的跟踪器部分进行替换，同时不使用 NSGA-II 进行跟踪器的超参数优化，对比不同跟踪器情况下，在本文建立的鱼类多目标跟踪数据集集中的表现。多目标跟踪效果的表现。从表 3.2 中可以看出，BYTE 在 HOTA 和 AssA 指标上表现最好，分别为 74.8 和 81.6，同时它的处理速度也是最快的，达到 40 帧/秒。HOTA 是跟踪准确度的综合指标，考虑了检测和身份识别的准确性，这证明了 BYTE 的综合表现较好。AssA 衡量跟踪器将检测正确关联到轨迹的能力，BYTE 通过关联每个检测框，包括高分检测框和低分检测框来进行跟踪，保留高分检测框，对于低分检测框也不是简单的丢弃，利用它们与轨迹的相似性来恢复真实目标并过滤掉背景的这一特性，使得它的正确关联能力较强。

虽然 BoT-SORT 在 MOTA 和 IDF1 指标上较高，分别为 61.2 和 44.7。但是 BYTE 和 OCSORT 是完全基于运动特征的跟踪算法，比起还需外观特征的跟踪算法，跟踪速度会快很多，FPS 相对较高。单纯从目标检测鱼类来跟踪的弊端在有遮挡和运动模糊时，外

观特征实际上是不可靠的，这个时候需要用运动特征来补足。另外，跟踪器获取外观特征需要的 Re-ID 模型，基本是针对行人训练的，对获取鱼类的外观特征没有太大帮助，所以选用基于运动特征的跟踪器对鱼类进行跟踪效果较好。因此，我们在 YO-BYNet 模型中使用了卡尔曼滤波器和 BYTE 关联方法。图 3.7 为 YO-BYNet 的多目标跟踪结果可视化。




图 3.7 YO-BYNet 的多目标跟踪结果可视化

3.2.3 对比实验

表 3.3 NSGA-II 对鱼类多目标跟踪效果的影响

Tracker	NSGA-II	HOTA↑	MOTA↑	IDF1↑	AssA↑	DetA↑
BYTE	√	76.8	61.3	40.7	82.0	72.0
		74.8	58.2	38.7	81.6	68.6
OC-SORT	√	66.2	63.7	42.3	72.6	60.4
		63.3	61.0	41.5	70.5	56.8




图 3.8 NSGA-II 对 YO-BYNet 效果的影响

本实验以 YOLOv8m 作为检测器，BYTE 和 OC-SORT 作为跟踪器，对比是否使用 NSGA-II 优化跟踪器的超参数在本文建立的鱼类多目标跟踪数据集中对跟踪结果的影响。从表 3.3 中和图 3.8 可以看出，使用 NSGA-II 遗传算法能够有效的提升跟踪器的性能，对每个指标都有不同程度的提升，从而提升鱼类多目标跟踪模型 YO-BYNet 的跟踪效果。排除外观特征的干扰，本实验选用了两个仅基于运动特征的跟踪算法进行对比实验。本实验使用遗传算法 NSGA-II 对 BYTE 的跟踪框阈值，跟踪框缓冲值，跟踪框与检测框匹配阈值以及 OC-SORT 的检测框阈值，最大保留时长，IoU 阈值，关联函数进行多参数优化，提升跟踪器性能。

3.3 本章小结

为更好的进行鱼类养殖研究，本章建立了一个鱼类多目标跟踪模型 YO-BYNet。鱼类多目标跟踪任务可以辅助养殖人员监测鱼类，并且获取多目标跟踪数据对鱼类进行进一步的研究，例如鱼类的行为分析，鱼类活跃度分类，鱼类投喂行为分析等。而本文是为了通过 YO-BYNet 获取鱼类活跃度特征序列以便进行鱼类活跃度分类模型的研究。

经过实验研究，对比各个规模的在各类多目标检测数据集达到 SOTA 的 YOLOv8 模型，选择了取得良好检测结果并且计算量适中速度较快的 YOLOv8m 模型。对比在各类多目标跟踪数据集达到 SOTA 的跟踪器模型，选择了跟踪效果较好的 BYTE 跟踪器。对比是否使用 NSGA-II 遗传算法对跟踪器超参数进行优化，表明使用 NSGA-II 对 YO-BYNet 的跟踪结果提升有帮助。本文建立了一个适合完成鱼类多目标跟踪任务的模型 YO-BYNet，该模型由 YOLOv8m、卡尔曼滤波、BYTE 关联方法、NSGA-II 遗传算法组成。YO-BYNet 在本文建立的鱼类多目标跟踪数据集中取得了良好的跟踪效果。

4 鱼类活跃度分类模型 FAC-Net

4.1 FAC-Net 模型结构




图 4.1 FAC-Net 模型结构

FAC-Net 鱼类活跃度分类的模型结构如图 4.1 所示，输入为鱼类视频到本文提出的 YO-BYNet 鱼类多目标跟踪模型，输出为鱼类的跟踪结果，将跟踪结果进行处理生成鱼类活跃度特征序列。然后将鱼类活跃度特征序列输入到基于 Transformer 的时间序列模型 PatchTST 中，PatchTST 进行特征提取。在 PatchTST 后加一个由全连接层，Softmax 组成的分类器使得 PatchTST 模型提取的特征映射到目标类别上，最后生成鱼类活跃度分类结果。PatchTST 原本使用的是 MSE loss，而 FAC-Net 模型是二分类模型，所以使用交叉熵损失函数(CrossEntropyLoss)。

4.1.1 FAC-Net 的时间序列模型

PatchTST 是一种基于 Transformer 的时间序列预测模型，如图 4.2 所示。模型接收多变量时间序列数据，每个变量视为一个通道。并且每个通道包含单一的单变量时间序列，所有序列共享相同的嵌入和 PatchTST 权重。这些数据被分割成小块(patches)，每个

块包含一定数量的连续时间点。每个时间序列块被转换成向量，并作为输入令牌(tokens)提供给 PatchTST。PatchTST 处理这些向量，通过自注意力机制学习时间序列中的模式和依赖关系。PatchTST 输出预测长度的预测结果，这些结果可以用于分类、回归或其他时间序列分析任务。




图 4.2 PatchTST 模型的总体结构

相比其他基于 Transformer 的时间序列模型，PatchTST 的优点包括：通过查看一组时间步骤而不是单个时间步骤，模型可以提取时间序列中的局部语义信息。注意力图由于给了相同的回溯窗口，使得计算和存储的资源减少。PatchTST 通过减少输入到 Transformer 编码器的令牌数量，大大降低了模型的空间和时间复杂性，使模型更快、更轻，并能处理更长的输入序列。与处理图片视频等 2 维数据不同，序列是 1 维数据，让基于 Transformer 的模型处理 1 维数据会比处理 2 维大大减少计算量，降低性能开销和增加速度。

另外一个重要的优点是 PatchTST 模型可以接受一个批次(batch)中包含不同长度序列的数据集，而不需要进行复杂的预处理来确保所有序列长度一致。这是因为该模型在处理输入数据时，会将时间序列划分成多个 patches，每个 patch 都可以独立地被模型处理。这种方法提供了灵活性，使得模型能够适应不同长度的时间序列，而不需要所有序列都是相同的长度。因此 PatchTST 可以直接接受本文不定长的鱼类活跃度特征序列。

本文使用的 PatchTST 中的 Transformer Backbone 如图 4.3 所示，其中 Head 数为 16，n 为 3。Transformer Backbone 中的具体步骤为：(1) 将输入的时间序列划分为多个 patches。这些 patch 可以有重叠，也可以没有重叠。每个 patch 的长度是预先设定的。(2) 将每个 patch 视为一个 token，对其进行 embedding 处理，并加上位置编码。这一步骤是为了让模型能够理解每个 patch 在序列中的位置。(3) 经过 embedding 的 patches（现在作为 tokens）输入到 Transformer 的 Encoder 中。Encoder 中是标准的 Transformer 结构被用来处理序列数据，通过自注意力机制捕捉 patch 之间的关系。(4) Transformer Encoder 的输出会被展平，然后输入到一个预测头（通常是一个线性层），以产生最终的时间序列预

测。




图 4.3 PatchTST 的 Transformer Backbone 结构

该模型具体需要调节的超参数有：**Patch 长度 P**，这决定了每个 patch 包含的时间步长数量。较小的 patch 可能捕获更细粒度的信息，而较大的 patch 可能更适合捕获长期依赖关系。由于鱼类活跃度不是短时间变化很快而是长时间观测的过程，所以需要较大的 patch。**步长 S**：这是连续 patch 之间的时间步长。步长可以是重叠的或不重叠的，这会影响模型如何从序列中提取信息。**回溯窗口长度 L**：这个参数定义了模型在做预测时会考虑的历史数据的时间范围。在 PatchTST 中，回溯窗口长度决定了输入序列被切分成多少个 patch，每个 patch 包含了一段时间序列的信息。回溯窗口越长，模型能够利用的历史信息就越多，这可能有助于捕捉更长期的依赖关系，但同时也可能增加模型的计算负担。**预测长度 T**：预测长度指的是模型需要预测未来多远的时间序列。本文需要实现的鱼类活跃度分类任务，会有水下视频实时传输到模型中，所以预测的长度设定不用过长。Patch 长度 P 设置为 16、步长 S 设置为 8 与 PatchTST 的论文设置相同。

4.1.2 FAC-Net 的分类器




图 4.4 FAC-Net 分类器

本文根据研究，发现基于 Transformer 的时间序列模型，例如 Informer、Autoformer 及本文所使用的 PatchTST 模型实现的主要为多变量序列预测多变量序列、多变量序列预测单变量序列、单变量序列预测单变量序列的回归任务，并未有分类任务的实现。所以想实现基于 Transformer 的时间序列模型分类需要对模型结构进行改进，从而实现分类任务。FAC-Net 分类器的基本结构如图 4.4 所示。

由于鱼类活跃度分类数据集数据较多，PatchTST 模型先进的性能，需要实现的任务是二分类，所以本文可以直接使用全连接层(Fully Connected Layer)和激活函数 Softmax 作为 FAC-Net 的分类器。PatchTST 模型的输出首先通过一个全连接层，这个层的作用是将模型的高维输出压缩至与目标分类数相匹配的维度。例如，在二分类任务中，全连接层会将输出压缩至 2 维。然后在全连接层之后应用深度学习中常用的 Softmax 函数，将输出转换为概率分布。Softmax 函数的主要作用是将一个实数向量归一化成一个概率分布。具体来说，它会将每个类别的得分转换为概率，这些概率的总和为 1，从而可以用来表示模型对每个类别的预测置信度。Softmax 函数的公式如(4.1)所示，其中 z 是输入向量， z_i 是模型输出的原始得分， K 是类别的总数。分子是 z_i 的指数，分母是所有类别得分指数的总和。

$$\text{Softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} \quad (4.1)$$

交叉熵损失(Cross-Entropy Loss)，用于计算模型预测和真实标签之间的差异，并指导模型在训练过程中的参数更新。在二分类任务中，它的公式简化为(4.2)所示。其中 N 是样本数量， p_i 是模型预测第 i 个样本为类别 1 的概率， y_i 是第 i 个样本的实际标签，其值为 0 或 1：

$$\text{BCE Loss} = -\frac{1}{N} \sum_{i=1}^N [y_i \cdot \log(p_i) + (1 - y_i) \cdot \log(1 - p_i)] \quad (4.2)$$

在本文使用 PyTorch 框架中，当使用 torch.nn.CrossEntropyLoss 作为损失函数时，不需要

显式地添加 Softmax 层。torch.nn.CrossEntropyLoss 结合了 Softmax 激活和交叉熵损失计算。它在内部先计算 log-softmax, 然后计算负对数似然损失(Negative Log Likelihood, NLL)。因此, 当使用这个损失函数时, 不需要在模型的最后显式地添加 Softmax 层, 因为损失函数已经包含了这一步骤。这样可以简化模型结构, 同时保持数值稳定性和计算效率。

4.2 实验结果分析

4.2.1 评估指标

分类模型的评估指标是用来衡量模型性能的关键指标, 它们帮助我们理解模型在预测分类时的准确性和效率。本文主要使用 F1 分数(F1 Score)[59]作为评估鱼类活跃度分类模型 FAC-Net 的指标。F1 分数是精确率和召回率的调和平均数, 是一个综合考虑精确率和召回率的指标。精确率(4.3)是指在所有被模型预测为正类的样本中, 实际为正类的样本的比例, 它反映了模型预测正类的准确性。召回率(4.4)是指在所有实际为正类的样本中, 被模型正确预测为正类的样本的比例。它反映了模型捕捉正类样本的能力。

F1 分数(4.5)是精确率和召回率的调和平均数, 它试图在两者之间找到一个平衡。当精确率和召回率都很重要时, F1 分数是一个有用的指标。F1 分数的取值范围是 0 到 1, 1 表示完美的精确率和召回率, 0 表示模型在这两个指标上表现最差。F1 分数非常适用于二分类问题。

$$Precision = \frac{True\ Positive}{True\ Positive + False\ Positive} \quad (4.3)$$

$$Recall = \frac{True\ Positive}{True\ Positive + False\ Negative} \quad (4.4)$$

$$F_1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (4.5)$$

4.2.2 实验结果

表 4.1 FAC-Net 不同预测长度时在鱼类活跃度分类数据集中的分类效果

Prediction Length(T)	F1 score(%) (F1 分数)↑	Precision(%) (精确率)↑	Recall(%) (召回率)↑
24	89.3	90.3	88.4
36	88.4	89.2	87.6
48	87.9	89.1	86.7
60	86.3	86.4	86.2
96	84.7	83.8	85.6
192	81.0	80.6	81.4
336	75.9	75.6	76.3
720	72.0	70.3	72.9

本实验测试了 FAC-Net 不同预测长度时在鱼类活跃度分类数据集中的分类效果，Patch 长度 P 设置为 16、步长 S 设置为 8、回溯窗口长度 L 设置为与 PatchTST 论文中默认的 336 相同。如表 4.1 所示，一共尝试了 {24,36,48,60,96,192,336,720} 八种预测长度，可以看出随着预测长度的增加，分类效果在变差。总体而言 {24,36,48,60,96} 这些预测长度相差不大，分类性能也差别较小，所以 PatchTST 在一定预测长度内能保持良好的性能。而预测长度 {192,336,720} 这些预测长度较长，模型的性能下降明显。

预测长度较长模型性能较差的原因可能是由于 PatchTST 采用通道独立性，如果一个通道中的数据存在噪声，可能会影响模型的整体性能。在水下实际拍摄中，会有一些鱼出现个例的特别情况，不能代表整个鱼群的整体情况，这个时候就会干扰鱼类的活跃度分类结果。也有可能是模型存在过拟合问题，因为采集视频过程中，有时候鱼群会保持相同状态一段时间，比如长时间游动或长时间静止，导致活跃度特征序列在一段时间内变化较小，模型可能会过拟合，导致泛化能力较差。

本文所需实现的鱼类活跃度分类不需要预测长度过长的序列，因为水下摄像机在实时传输视频，所以只需要较短的预测长度就可以实现鱼类活跃度实时分类的功能。因此，本文将 FAC-Net 中的 PatchTST 的预测长度 T 设置为 24。




图 4.5 不同时间序列模型在不同回溯窗口长度下的分类效果

如图 4.5 所示，本实验为 FAC-Net 替换不同时间序列模型在不同回溯窗口长度 L 下的分类效果，其中根据表 4.1 的实验，预测长度 T 设置为 24，时间序列模型选用 Informer、Autoformer、FEDformer、PatchTST，回溯窗口长度 L 选择 {24,48,96,192,336} 这一组数据。而 LTSF-Linear 线性模型没有回溯窗口长度这一设置，Pyraformer 的回溯窗口长度

是一个常数，所以无法加入到该实验。其中可以看出 PatchTST 在各个回溯窗口长度下均优于其他几个模型，并且回溯窗口长度越长分类效果越好。因此设置回溯窗口长度为 336，并且与 Informer、Autoformer、FEDformer 相比优势较明显。

表 4.2 不同时间序列模型在本文鱼类活跃度分类数据集中的表现

时间序列模型	F1 score(%) (F1 分数)↑	Precision(%) (精确率)↑	Recall(%) (召回率)↑
LTSF-Linear	77.8	80.2	75.6
Informer	81.7	80.3	83.1
Autoformer	84.9	85.2	84.7
Pyraformer	85.2	86.1	84.5
FEDformer	84.8	83.8	85.9
PatchTST	89.3	90.3	88.4

本实验将本文提出的 FAC-Net 中的时间序列模型 PatchTST 替换成不同的时间序列模型，对比它们在本文建立的鱼类活跃度分类数据集中的分类表现，其中根据表 4.1 的实验预测长度 T 设置为 24，根据图 4.5 的实验回溯窗口长度 L 设置为 336。从实验结果表 4.1 中可以看出，PatchTST 的模型性能总体优于其他基于 Transformer 的时间序列模型和线性模型。线性模型在简单短时间的应用场景可能效果较好且性能消耗少，但面对长时间较大数据集的情况下，仍然是基于 Transformer 的模型效果更佳。Transformer 近年应用到多个领域都取得了较好的效果，而该模型还增加了 patch 的设计使得模型能够保留并提取序列的局部特征，有利于改善长期预测的准确性。在长时间时间序列的预测任务上也是如此。此外由于不用处理二维图片或三维视频的数据，时间序列是一维的数据，同时通过 patching 操作，可以将输入 token 的数量降低，从而大大降低了计算时间和内存的复杂度。即使是基于 Transformer 的模型，也不需要消耗很大的计算资源，计算速度也较快，FAC-Net 的分类速度可达到 30FPS，能运用到实际生产研究中去。因此，FAC-Net 中选用 PatchTST 作为其中的时间序列模型。

4.3 本章小结

本章介绍了上一章节的 YO-BYNet 相结合的鱼类活跃度分类模型 FAC-Net 的模型结构，该模型内部的时间序列模型 PatchTST 的结构和原理，分类器的具体结构，以及适用于分类模型的评估指标介绍。对比实验了 PatchTST 不同预测长度时在本文提出的鱼类活跃度分类数据集中的分类效果，根据实验将预测长度 T 设置为 24。对比实验了不同时间序列模型在不同回溯窗口长度下的分类效果，根据实验选用回溯窗口长度为 336 的设置。对比实验了不同时间序列模型在本文建立的鱼类活跃度分类数据集中的表现，最终选用分类效果最好的 PatchTST 作为 FAC-Net 的时间序列模型。

5 鱼类福利养殖监测系统

5.1 系统介绍

结合智慧农业，福利养殖的理念，本文提出了一个鱼类福利养殖监测系统，利用前文提出的鱼类活跃度分类模型 FAC-Net 能够有效的对一定时间段内的鱼类的活跃度进行二分类判断，辅助养殖人员监测鱼类的状态，应用于实际的生活环境中可以一定程度上减少人力成本。只要部署多个水下摄像头就可以同时监测多个工厂化养殖池的鱼类活跃度状况。

该系统的实验基地为山东东方海洋科技股份有限公司开发区分公司的鱼类研究中心，如图 5.1 所示，该实验基地 2010 年从挪威引进大西洋鲑卵及全套大西洋鲑循环水育苗装备和管理技术，利用厂区内的恒低温 12-15 摄氏度的地下海水资源，现已建成养殖车间 16 个，养殖水体 36800m²，实现大西洋鲑商品鱼的大规模工业化循环水养殖，养成的东方海洋三文鱼在第十届、第十一届中国国际农产品交易会上获得金奖。



图 5.1 鱼类研究中心实验基地

该系统主要实现的功能有：

(1) 用户登录功能：分为普通用户和管理员用户，普通用户可查看实时监测画面和数据，查看监测日志，管理员用户除了拥有普通用户的权限，还可管理其他用户和监测日志。

(2) 截取视频和上传功能：使用水下摄像头采集视频，采集的视频通过 Wi-Fi 实时传输到系统中，系统以一定间隔提取时间长度为 10s 的视频数据样本并上传至部署了本文提出的鱼类活跃度分类模型 FAC-Net 的服务器。

(3) 鱼类活跃度分类功能：使用该模型进行鱼类活跃度分类，服务器将该模型的分类结果传回到前端，前端接收鱼类活跃度分类结果。

(4) 数据展示功能：系统显示该视频样本的鱼类活跃度分类结果，如若还有溶解氧含量，PH 值，水温等传感器数据传到系统也可同时显示在系统上。

(5) 系统日志功能：系统会自动记录每次采集的视频数据样本以及对应的时间、鱼类活跃度分类结果以及其他传感器数据。




图 5.2 鱼类福利养殖监测系统架构图

本系统实现上述功能的系统结构图如图 5.2 所示，帮助养殖人员能够更清晰明了的掌握鱼类养殖福利，并且能对监测情况加以自动记录和管理，为养殖人员带来便利。该系统辅助养殖人员监测鱼类福利，使其能更及时发现异常状况并排查，以此减小鱼类养殖的损失和风险，提升鱼类养殖的经济效益。

5.2 应用流程

根据养殖基地实际生产状况和研究需要，选择了第 16 号车间作为实验采集车间。如图 5.3 所示，该车间共有 6 个循环养殖池，养殖鱼类为大西洋鲑，每个养殖池中大约有 750 尾大西洋鲑，养殖池深度为 2m，底面积约为 100.5m²，容量为 201m³。为了将摄像机稳定地固定在水下，使用了 Z 字形设计的摄像平台支架。由于实验器材有限，选用了 GoPro HERO7 Black 水下摄像机进行拍摄，但若需进一步投入生产使用，需在水下安装固定摄像头并有直接供电。




图 5.3 实验基地布置概念图

本文的鱼类福利养殖系统在实际的应用场景中的应用流程如图 5.4 所示，先建立鱼类活跃度分类数据集，将 FAC-Net 部署到服务器，对其进行预训练，再将训练好的 FAC-Net 模型进行保存以供后续加载使用。然后在养殖池中安装好水下摄像头，水下摄像头实时采集工厂化循环水养殖池内的鱼类视频，通过 Wi-Fi 传输到系统，系统会每隔固定的时间，截取一定时间长度(如 10s)的视频样本，上传到服务器，输入到训练好的 FAC-Net 模型中，模型会输出鱼类活跃度分类结果，与获取的其他传感器数据一起记录到系统中，并显示在系统界面上。




图 5.4 鱼类福利养殖监测系统应用流程

若需要将此模型应用于其他的鱼类养殖基地中，首先需要完成数据采集设备的安装，采集视频数据。然后按前文提到的鱼类活跃度分类数据集的构建方法，进行数据集的构建，且活跃和不活跃的样本数量需要大致相同。再将搭建好的 FAC-Net 模型用制作好的数据集进行训练，训练过程中需要调整超参数等，等到模型各类评估指标较好则模型训练完毕。

5.3 系统设计与界面

为了能实时监测鱼类活跃度情况，本文设计并开发了鱼类福利养殖监测系统。该系统可实现登录、实时监测、视频录制和显示活跃度分类、溶解氧含量、PH 值、水温、活跃度低提醒和系统设置、系统日志等功能。该系统主要包含四个界面，分别是登录界面、主监测界面、系统日志界面、系统设置界面。

系统登录界面如图 5.5 所示，使用用户名和密码登录，登录后系统自动根据设置为普通用户和管理员用户。普通用户只能查看数据和记录，管理员用户可以查看和删除记录。主要是保证鱼类养殖基地的数据保密，防止非工作人员对采集的数据进行不恰当的处理或者获取到不必要的信息，影响鱼类的养殖情况监测。



图 5.5 系统登录界面

系统主界面如图 5.6 所示包含实时监测画面、视频录制、鱼类活跃度显示、显示溶解氧含量、PH 值、水温等功能，系统会自动调用服务器部署好的鱼类活跃度分类模型，依据 FAC-Net 模型自动判断 10s 内鱼类的活跃状态，也可通过设置更改一定范围的时间间隔，显示活跃度分类结果，若此时鱼类活跃度为活跃显示会有紫色光晕，不活跃没有紫色光晕。监测画面中不同颜色的框代表不同 ID 的鱼，并在框的左上角也标有 ID，可对鱼类进行实时的多目标跟踪，方便养殖人员监测。




图 5.6 系统主界面

如图 5.7 是系统监测鱼类活跃度为不活跃时的情况，会有鱼类活跃度监测提醒的弹窗，用户可以选择关闭提醒或者查看监测为不活跃的活跃度记录。并且活跃度显示不活跃时紫色光晕消失。



图 5.7 系统鱼类活跃度监测提醒界面

系统日志界面如图 5.8 所示，该界面会统计显示总共的记录条数，鱼类活跃的记录条数和鱼类不活跃的记录条数。记录的内容包括记录编号、记录时间、溶解氧含量、PH 值、水温、活跃度，活跃会显示绿色不活跃显示红色。并且该记录可根据条件排序，例如时间从新到旧或从旧到新排序。还可根据记录编号或记录时间进行搜索并显示记录搜索结果。普通用户可对所有记录进行查看和搜索，管理员用户在此基础上可以手动删除所选记录。



图 5.8 系统日志界面

系统设置界面如图 5.9 所示，普通用户可更改自己的用户名、email、头像，可对密码进行重新设置，可设置鱼类不活跃时是否提醒。管理员用户在此基础上，能对系统日志进行导出，方便批量留存和处理。还可以进行用户管理，实现对普通用户账户的添加、删除、重置密码、搜索等功能。




图 5.9 系统设置界面

5.4 本章小结

本章主要围绕鱼类福利养殖监测系统的介绍、应用流程、系统设计与界面三个部分展开。鱼类福利养殖监测系统的介绍部分主要讲了实验基地的概况，养殖车间的选取以及系统结构。鱼类福利养殖监测系统主要包括了五个功能模块，分别是用户登录模块、视频上传模块、鱼类活跃度分类模块、数据结果展示模块、系统日志模块。然后介绍了如何将该系统部署和使用的应用流程。最后根据登录界面、主监测界面、系统日志界面、系统设置界面、系统活跃度监测提醒这五个界面讲述了系统的每一部分功能的设计与实现。

6 总结与展望

6.1 工作总结

本文研究以大西洋鲑为对象,通过采集工厂化循环水养殖池中的水下视频,创建了一个鱼类活跃度分类数据集。本文提出了 YO-BYNet,一种基于目标检测的鱼类多目标跟踪模型,以及 FAC-Net,一个鱼类活跃度分类模型,并设计了一个鱼类福利养殖监控系统。尽管计算机视觉技术近年来取得了飞速进展,但在福利养殖领域的应用仍然有限。为了将这些先进技术应用于实际,本文提出了 FAC-Net 模型,该模型通过将复杂的三维视频数据转化为简单的一维数据,从而解决了直接将视频输入基于 Transformer 的模型时所面临的高计算量、长时间和高性能要求的问题,使之能够有效地应用于鱼类养殖实践。本文的主要工作如下:

(1) 本文通过水下摄像头采集真实的鱼类工厂化循环水养殖视频,建立了一个鱼类活跃度分类数据集。这个数据集分为三个部分:一是多目标检测数据集,用于训练 YO-BYNet 模型的检测器;二是多目标跟踪数据集,用于训练 YO-BYNet 模型的跟踪器;三是鱼类活跃度分类数据集,用于训练 FAC-Net 模型。

(2) 本文提出了 YO-BYNet 鱼类多目标跟踪模型,它结合了 YOLOv8 检测器、卡尔曼滤波器和 BYTE 关联方法,并通过 NSGA-II 遗传算法进行了多目标优化。该模型通过 HOTA 评估方法得到了验证,显示出优秀的多目标跟踪性能。将采集的鱼类视频输入到该模型中,获取鱼的 ID 和位置坐标,从而计算出游速,根据这些数据获得鱼类活跃度特征序列以进行下一步对鱼类活跃度分类的研究。

(3) 本文提出了 FAC-Net 鱼类活跃度分类模型,它包含了 YO-BYNet 和生成活跃度特征序列过程,并将其输入到基于 Transformer 的时间序列模型 PatchTST 和分类器中,实现了对鱼类活跃度的有效二分类。

(4) 本文设计并实现了一个鱼类福利养殖监测系统。该系统不仅能够采集鱼类养殖视频,还能将视频数据输入 FAC-Net 模型中,进行鱼类活跃度监测和异常预警,从而协助养殖人员及时发现并处理鱼类的异常状态。这一系统的实现,可有效提高鱼类养殖的福利和管理效率。

6.2 工作展望

本研究基于工厂化循环水养殖,是在真实的养殖环境中进行,本文建立了鱼类活跃度分类数据集,构建了鱼类多目标跟踪模型 YO-BYNet,鱼类活跃度分类模型 YO-BYNet,建立了鱼类福利养殖监测系统,实现了鱼类活跃度的二分类。但鱼类福利养殖相关的技

术还有较大空白，还有很多工作和方向可以改进和深入，本文总结如下：

本文提出的鱼类活跃度分类数据集有可以改进的地方，由于拍摄的是水下环境，会有色差，光线不足，水中颗粒物影响视觉效果等问题，因此可以进行水下图像增强，本文曾经尝试过一些水下图像增强的方法，但效果并不理想。若能找到合适的水下图像增强方法，也会使该研究的多目标跟踪结果，分类结果更进一步提升。

本文提出的鱼类多目标跟踪模型 YO-BYNet 还有更进一步的改进空间。目前多目标检测模型完成鱼类多目标检测任务的表现已十分优秀，但完成多目标跟踪任务仍不理想，为了提升跟踪器性能，未来还有将普通的卡尔曼滤波器替换成其他的卡尔曼滤波器改进版，增加相机运动补偿等方式。另外在实验中可以发现，鱼游动时距离相机过近，游速过快时，会出现对焦失败导致的模糊和运动模糊，从而影响模型性能。选取合适的拍摄角度和位置，更好的摄像机也会对模型的性能提升有所帮助。

本文提出的鱼类活跃度分类模型 FAC-Net 有一定局限性，一是对不同的鱼判断活跃度都需要重新制作数据集和训练模型。本文的数据集是针对大西洋鲑制作的，本模型根据我们制作的数据集训练出来的鱼类活跃度分类模型仅对大西洋鲑有效，如果要判断其他品种鱼的活跃度，就需要重新采集视频，重新人工制作数据集。不同种类的鱼的活跃与否的表现和判断标准都不同，需要根据不同种类的鱼制作对应的数据集，重新训练模型，从而能完成活跃度二分类的任务。

二是该模型无法判断同一个养殖池内有多种鱼的情况下每一种鱼的活跃度。如果同一个养殖池混养鱼，该模型就难以同时判断多种鱼的活跃度，只适用于一个养殖池只有一种鱼的情况。在实际生产养殖情况中，计算机视觉能起到的作用有限，可能还需要通过一些物理化学上的条件来综合判断会更具有普适性。

三是该模型仅实现了鱼类活跃度的二分类，原因是从采集的视频中较难标注多级分类，鱼类的活跃和不活跃二分类是比较容易观测，但要将中间状态分级就比较难定义和分辨。模型若是能判断更为具体的活跃度变化，能够更精准的预测鱼类活跃度变化并采取措施，会对福利养殖有更大的帮助。

参考文献

- [1] 韩刚, 许玉艳, 刘琪, 等. 科学制定水产养殖业绿色发展标准的思考与建议[J]. 中国渔业质量与标准, 2019, 9(5): 55-60.
- [2] 沈晋发. 浅议推行水产健康养殖[J]. 渔业经济研究, 2007(4):33-35. DOI:10.3969/j.issn.1674-9189.2007.04.009.
- [3] 王安利, 廖绍安. 发展循环经济(Circular Economy)促进水产健康养殖[J]. 现代渔业信息, 2006, 21(12):3-6. DOI:10.3969/j.issn.1004-8340.2006.12.001.
- [4] 雷霖霖, 黄滨, 刘滨, 等. 构建基于水产福利养殖理念的高端养殖战略研究[J]. 中国工程科学, 2014(3):14-20. DOI:10.3969/j.issn.1009-1742.2014.03.002.
- [5] Wishkerman A, Boglino A, Darias M J, et al. Image analysis-based classification of pigmentation patterns in fish: A case study of pseudo-albinism in Senegalese sole[J]. Aquaculture, 2016, 464: 303-308.
- [6] Kolarevic J, Aas-Hansen Ø, Espmark Å, et al. The use of acoustic acceleration transmitter tags for monitoring of Atlantic salmon swimming activity in recirculating aquaculture systems (RAS) [J]. Aquacultural engineering, 2016, 72: 30-39.
- [7] 何佳, 黄志涛, 宋协法, 等. 基于计算机视觉技术的水产养殖中鱼类行为识别与量化研究进展[J]. 渔业现代化, 2019, 46(3):7-14. DOI:10.3969/j.issn.1007-9580.2019.03.002.
- [8] Svendsen E, Føre M, Økland F, et al. Heart rate and swimming activity as stress indicators for Atlantic salmon (*Salmo salar*) [J]. Aquaculture, 2021, 531: 735804.
- [9] 徐建瑜. 基于计算机视觉的急性应激条件下尼罗罗非鱼的行为研究[D]. 浙江: 浙江大学, 2005.
- [10] 夏继刚, 刘香, 黄艳. 高体鳊鲂化学预警响应与“个性”行为的关联[J]. 生态学报, 2019, 39(17):6425-6432. DOI:10.5846/stxb201808191764.
- [11] 孙杰, 陈再忠. 利用鱼类在线预警系统对重金属暴露下斑马鱼行为的分析和比较[J]. 江苏农业科学, 2012, 40(10):206-208. DOI:10.3969/j.issn.1002-1302.2012.10.077.
- [12] 王蕾. 食物丰度对宽鳍鳊维持能量消耗、个性和集群的影响及其之间的关联[D]. 重庆: 重庆师范大学, 2019.
- [13] 路波, 白艳勤, 罗佳, 刘德富, 石小涛, 陈求稳, 黄应平. 葛洲坝下游中华鲟产卵场瓦氏黄颡鱼摄食活动的试验研究[J]. 生态学杂志, 2013, 32(10):2728-2734. DOI:10.13292/j.1000-4890.2013.0295.
- [14] Kristiansen T S, Fernö A, Holm J C, et al. Swimming behaviour as an indicator of low growth rate and impaired welfare in Atlantic halibut (*Hippoglossus hippoglossus* L.) reared at three stocking densities[J]. Aquaculture, 2004, 230(1-4): 137-151.
- [15] 易恋淳, 肖玲韬, 付世建, 付成. 短期捕食胁迫对中华倒刺鲃幼鱼行为特征的影响[J]. 重庆师范大学学报(自然科学版), 2019, 36(02):31-36.
- [16] 杨咏文. 基于图像和声音的鲫鱼活跃度识别[D]. 华中农业大学, 2020. DOI:10.27158/d.cnki.ghznu.2020.000266.
- [17] 唐宸. 多场景鱼群摄食行为分析及投饵控制系统研究[D]. 同济大学, 2022.
- [18] 黄薪. 基于机器视觉的户外养殖淡水鱼自动投饵研究[D]. 同济大学, 2022.
- [19] Welch G, Bishop G. An introduction to the Kalman filter[J]. 1995.

- [20]Bewley A, Ge Z, Ott L, et al. Simple online and realtime tracking[C]//2016 IEEE international conference on image processing (ICIP). IEEE, 2016: 3464-3468.
- [21]Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39 (6): 1137-1149.
- [22]Wojke N, Bewley A, Paulus D. Simple online and realtime tracking with a deep association metric[C]//2017 IEEE international conference on image processing (ICIP). IEEE, 2017: 3645-3649.
- [23]Aharon N, Orfaig R, Bobrovsky B Z. BoT-SORT: Robust associations multi-pedestrian tracking [J]. arXiv preprint arXiv:2206.14651, 2022.
- [24]Ge Z, Liu S, Wang F, et al. YOLOX: Exceeding yolo series in 2021[J]. arXiv preprint arXiv:2107.08430, 2021.
- [25]Du Y, Zhao Z, Song Y, et al. StrongSORT: Make deepSORT great again[J]. IEEE Transactions on Multimedia, 2023, 25: 8725-8737.
- [26]Cao J, Pang J, Weng X, et al. Observation-centric sort: Rethinking sort for robust multi-object tracking[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 9686-9696.
- [27]Maggiolino G, Ahmad A, Cao J, et al. Deep oc-sort: Multi-pedestrian tracking by adaptive re-identification[J]. arXiv preprint arXiv:2302.11813, 2023.
- [28]Zhang Y, Sun P, Jiang Y, et al. ByteTrack: Multi-object tracking by associating every detection box[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2022: 1-21.
- [29]Pang B, Li Y, Zhang Y, et al. Tubetrack: Adopting tubes to track multi-object in a one-step training model[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 6308-6318.
- [30]Wang Z, Zheng L, Liu Y, et al. Towards real-time multi-object tracking[C]//European Conference on Computer Vision. Springer, Cham, 2020: 107-122.
- [31]Zhou X, Koltun V, Krähenbühl P. Tracking objects as points[C]//European Conference on Computer Vision. Springer, Cham, 2020: 474-490.
- [32]Duan K, Bai S, Xie L, et al. Centernet: Keypoint triplets for object detection[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 6569-6578.
- [33]Zhang Y, Wang C, Wang X, et al. Fairmot: On the fairness of detection and re-identification in multiple object tracking[J]. International Journal of Computer Vision, 2021, 129: 3069-3087.
- [34]毛远宏, 孙琛琛, 徐鲁豫, 等. 基于深度学习的时间序列预测方法综述[J]. 微电子学与计算机, 2023, 40(4): 8-17.
- [35]李文, 邓升, 段妍, 等. 时间序列预测与深度学习: 文献综述与应用实例[J]. 计算机应用与软件, 2020, 37(10): 64-70.
- [36]Medsker L R, Jain L C. Recurrent neural networks[J]. Design and Applications, 2001, 5(64-67): 2.
- [37]Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30: 5999.
- [38]Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 173

- 5-1780.
- [39] Chung J, Gulcehre C, Cho K H, et al. Empirical evaluation of gated recurrent neural networks on sequence modeling[J]. arXiv preprint arXiv:1412.3555, 2014.
- [40] Zhou H, Zhang S, Peng J, et al. Informer: Beyond efficient transformer for long sequence time series forecasting[C]//Proceedings of the AAAI conference on artificial intelligence. 2021, 35(12): 11106-11115.
- [41] Wu H, Xu J, Wang J, et al. Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting[J]. Advances in Neural Information Processing Systems, 2021, 34: 22419-22430.
- [42] Liu S, Yu H, Liao C, et al. Pyraformer: Low-complexity pyramidal attention for long-range time series modeling and forecasting[C]//International conference on learning representations. 2021.
- [43] Zhou T, Ma Z, Wen Q, et al. Fedformer: Frequency enhanced decomposed transformer for long-term series forecasting[C]//International Conference on Machine Learning. PMLR, 2022: 27268-27286.
- [44] Nie Y, Nguyen N H, Sinthong P, et al. A time series is worth 64 words: Long-term forecasting with transformers[J]. arXiv preprint arXiv:2211.14730, 2022.
- [45] Zeng A, Chen M, Zhang L, et al. Are transformers effective for time series forecasting?[C]//Proceedings of the AAAI conference on artificial intelligence. 2023, 37(9): 11121-11128.
- [46] Deb K, Pratap A, Agarwal S, et al. A fast and elitist multiobjective genetic algorithm: NSGA-II[J]. IEEE transactions on evolutionary computation, 2002, 6(2): 182-197.
- [47] Voigtlaender P, Krause M, Osep A, et al. Mots: Multi-object tracking and segmentation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 7942-7951.
- [48] Wang X, Gao H, Jia Z, et al. BL-YOLOv8: An improved road defect detection model based on YOLOv8[J]. Sensors, 2023, 23(20): 8361.
- [49] Bochkovskiy A, Wang C Y, Liao H Y M. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.
- [50] Liu S, Qi L, Qin H, et al. Path aggregation network for instance segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 8759-8768.
- [51] Wang C Y, Liao H Y M, Wu Y H, et al. CSPNet: A new backbone that can enhance learning capability of CNN[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops. 2020: 390-391.
- [52] Feng C, Zhong Y, Gao Y, et al. Tood: Task-aligned one-stage object detection[C]//2021 IEEE/CVF International Conference on Computer Vision (ICCV). IEEE Computer Society, 2021: 3490-3499.
- [53] Mao A, Mohri M, Zhong Y. Cross-entropy loss functions: Theoretical analysis and applications [C]//International Conference on Machine Learning. PMLR, 2023: 23803-23828.
- [54] Li X, Wang W, Wu L, et al. Generalized focal loss: Learning qualified and distributed bounding boxes for dense object detection[J]. Advances in Neural Information Processing Systems, 2020, 33: 21002-21012.
- [55] Zheng Z, Wang P, Ren D, et al. Enhancing geometric factors in model learning and inference

- for object detection and instance segmentation[J]. IEEE transactions on cybernetics, 2021, 52(8): 8574-8586.
- [56]Akiba T, Sano S, Yanase T, et al. Optuna: A next-generation hyperparameter optimization framework[C]//Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining. 2019: 2623-2631.
- [57]Luiten J, Osep A, Dendorfer P, et al. Hota: A higher order metric for evaluating multi-object tracking[J]. International journal of computer vision, 2021, 129: 548-578.
- [58]Bernardin K, Stiefelhagen R. Evaluating multiple object tracking performance: the clear mot metrics[J]. EURASIP Journal on Image and Video Processing, 2008, 2008: 1-10.
- [59]Goutte C, Gaussier E. A probabilistic interpretation of precision, recall and F-score, with implication for evaluation[C]//European conference on information retrieval. Berlin, Heidelberg: Springer Berlin Heidelberg, 2005: 345-359.